YouTube 영상 조회수 예측 모델 구축

- **채널 특성과 메타데이터 기반 End-to-End ML 파이프라인**

---

1. 프로젝트 개요

1.1 프로젝트 배경 및 목표

YouTube 크리에이터들에게 영상 업로드 전 예상 조회수를 제공하여 콘텐츠 전략 수립을 돕는 것을 목표로 합니다. 단순히 모델을 만드는 것이 아니라, **데이터 수집부터 모델 배포까지 전체 ML 파이프라인**을 직접 설계하고 구현했습니다.

- **핵심 목표:**
  - 업로드 **'전'**에 알 수 있는 정보만으로 조회수 예측
  - 데이터 수집 → 저장 → 분석 → 모델링 → 배포 전체 파이프라인 구축
  - 실제 서비스 가능한 API 형태로 배포

1.2 기술 스택

분야	기술
데이터 수집	Python, YouTube Data API v3
데이터 저장	Google BigQuery
데이터 분석	BigQuery SQL, EDA
머신러닝	BigQuery ML (Linear Regression, Boosted Tree), Vertex AI AutoML
모델 배포	Vertex AI Endpoint (REST API)

1.3 프로젝트 흐름

[YouTube API] → [BigQuery 저장] → [EDA] → [Feature Engineering] → [모델 학습] → [Vertex AI 배포]

---

2. 데이터 수집 및 저장

2.1 데이터 수집 개요

YouTube Data API v3를 활용하여 음식/요리 관련 채널의 영상 메타데이터를 수집했습니다.

- **수집 대상:** 음식/요리 카테고리 영상
- **수집 영상 수:** 68,497개
- **수집 컬럼 수:** 15개

2.2 수집 데이터 스키마 (전체 15개 컬럼)

컬럼명	타입	설명
video_id	STRING	영상 고유 식별자
title	STRING	영상 제목
description	STRING	영상 설명

channel_id	STRING	채널 고유 식별자
channel_title	STRING	채널명
category_id	STRING	YouTube 카테고리 ID
tags	STRING	영상 태그 (쉼표 구분)
duration	STRING	영상 길이 (ISO 8601 형식)
duration_seconds	INTEGER	영상 길이 (초 단위 변환)
view_count	**INTEGER**	**조회수 (예측 타겟)**
like_count	INTEGER	좋아요 수
comment_count	INTEGER	댓글 수
subscriber_count	INTEGER	채널 구독자 수
published_at	TIMESTAMP	영상 업로드 일시
collected_at	TIMESTAMP	데이터 수집 일시

3. 탐색적 데이터 분석 (EDA)

EDA의 목적은 단순히 데이터를 보는 것이 아니라, **Feature Engineering에서 '무엇을 해야 할지' 힌트를 얻는 것**입니다.

3.1 데이터 품질 확인

- **분석 쿼리:**

```
SELECT
 COUNT(*) as total_rows,
 COUNTIF(view_count IS NULL) as null_views,
 COUNTIF(title IS NULL) as null_titles,
 COUNT(DISTINCT video_id) as unique_videos
FROM video_stats_v1
```

- **분석 결과:**

항목	결과
전체 데이터 수	68,497
결측치	0개 (모든 컬럼)
중복 데이터	0개 (unique_videos = total_rows)

→ **의사결정:** 결측치/중복 처리 불필요. 바로 분포 분석으로 진행

3.2 조회수 분포 분석

- **분석 쿼리:**

```
SELECT
 COUNTIF(view_count <= 1000) as views_under_1k,
 COUNTIF(view_count > 1000 AND view_count <= 10000) as views_1k_10k,
 COUNTIF(view_count > 10000 AND view_count <= 100000) as views_10k_100k,
 COUNTIF(view_count > 100000 AND view_count <= 1000000) as views_100k_1m,
 COUNTIF(view_count > 1000000) as views_over_1m,
```

```
 APPROX_QUANTILES(view_count, 100)[OFFSET(50)] as median_views
FROM video_stats_v1
```

- **분석 결과:**

조회수 구간	영상 수	비율	누적
0 ~ 1천	4,484	6.5%	6.5%
1천 ~ 1만	14,578	21.3%	27.8%
1만 ~ 10만	**24,355**	**35.5%**	63.3%
10만 ~ 100만	19,628	28.6%	91.9%
100만 이상	5,452	8.0%	100%

- **핵심 발견:**
  - 중앙값: 42,431회 vs 평균: 815,539회 → **약 20배 차이**
  - 최댓값: 12억 6천만회 → 극단적 이상치 존재
  - 전형적인 **'롱테일 분포'** 확인

→ 의사결정: 로그 변환(Log Transformation) 필요. 극단값이 모델 학습을 왜곡할 수 있음

3.3 시간대별 조회수 패턴 분석

- **분석 쿼리:**

```
SELECT
 EXTRACT(DAYOFWEEK FROM published_at) as day_of_week,
 EXTRACT(HOUR FROM published_at) as hour,
 AVG(view_count) as avg_views,
 APPROX_QUANTILES(view_count, 100)[OFFSET(50)] as median_views
FROM video_stats_v1
GROUP BY 1, 2
ORDER BY median_views DESC
```

- **핵심 발견:**
  - 토요일 새벽~아침 업로드 영상의 중앙값 조회수가 가장 높음
  - 평균값은 극단값에 영향받아 패턴이 왜곡됨 → 중앙값 기준 분석이 더 신뢰성 있음

→ 의사결정: day_of_week, hour를 Feature로 추가. 시간 정보가 예측에 유의미할 것으로 판단

3.4 채널 규모별 조회수 분석

채널 평균 조회수	영상 수	실제 평균 조회수	배수
1만 미만	7,436	4,341회	1x
1만 ~ 10만	21,783	46,632회	11x
10만 ~ 100만	33,845	348,304회	80x
100만 이상	5,418	**7,941,224회**	**1,830x**

→ 의사결정: 채널 평균 조회수(log_channel_avg_views)를 핵심 Feature로 추가. 채널 파워가 조회수의 핵심 결정 요인임을 확인

---

4. Feature Engineering

EDA에서 발견한 인사이트를 바탕으로 원시 데이터를 ML 모델이 학습할 수 있는 형태로 변환했습니다.

4.1 Feature 설계 원칙

1. **업로드 '전'에 알 수 있는 정보만 사용** - 실제 예측에 활용 가능해야 함
2. **수치형 변환** - ML 모델은 숫자만 이해함
3. **스케일 정규화** - 극단값 영향 최소화 (로그 변환)

4.2 생성된 Feature 목록 (17개)

카테고리	Feature	변환 방법 및 근거
채널 정보	log_subscribers	LOG(subscriber_count + 1) - 스케일 정규화
채널 정보	log_channel_avg_views	채널별 AVG(view_count) 집계 후 로그 변환
채널 정보	channel_video_count	채널별 영상 수 집계
시간 정보	day_of_week	EXTRACT(DAYOFWEEK FROM published_at)
시간 정보	hour	EXTRACT(HOUR FROM published_at)
시간 정보	month	EXTRACT(MONTH FROM published_at)
제목 분석	title_length	LENGTH(title)
제목 분석	has_mukbang	REGEXP_CONTAINS(title, r'(?i)먹방|mukbang')
제목 분석	has_recipe	REGEXP_CONTAINS(title, r'(?i)레시피|recipe')
제목 분석	has_review	REGEXP_CONTAINS(title, r'(?i)리뷰|review')
제목 분석	has_asmr	REGEXP_CONTAINS(title, r'(?i)asmr')
제목 분석	has_vlog	REGEXP_CONTAINS(title, r'(?i)vlog|브이로그')
제목 분석	has_multiple_punct	REGEXP_CONTAINS(title, r'[!?]{2,}')
제목 분석	has_special_chars	특수문자 비율 10% 이상 여부
콘텐츠 정보	duration_seconds	원본 그대로 사용
콘텐츠 정보	tag_count	ARRAY_LENGTH(SPLIT(tags, ','))
콘텐츠 정보	category_id	범주형 변수로 사용

4.3 전처리 테이블 생성 SQL

```
CREATE OR REPLACE TABLE video_stats_processed_v2 AS
WITH channel_stats AS (
 SELECT
  channel_id,
```

```
  AVG(view_count) as channel_avg_views,
  COUNT(*) as channel_video_count
 FROM video_stats_v1
 GROUP BY channel_id
)
SELECT
 v.video_id,
 LOG(v.view_count + 1) as log_view_count,
 LOG(v.subscriber_count + 1) as log_subscribers,
 LOG(c.channel_avg_views + 1) as log_channel_avg_views,
 c.channel_video_count,
 EXTRACT(DAYOFWEEK FROM v.published_at) as day_of_week,
 EXTRACT(HOUR FROM v.published_at) as hour,
 EXTRACT(MONTH FROM v.published_at) as month,
 LENGTH(v.title) as title_length,
 REGEXP_CONTAINS(v.title, r'(?i)먹방|mukbang') as has_mukbang,
 ... (나머지 Feature 변환)
FROM video_stats_v1 v
LEFT JOIN channel_stats c ON v.channel_id = c.channel_id
WHERE v.view_count > 0 AND v.subscriber_count IS NOT NULL
```

4.4 Data Leakage 문제 발견 및 해결

초기 모델에서 ****예상보다 높은 R^2 = 0.95****가 나와 의심을 갖게 되었습니다.

문제 발견 과정:

1. like_count, comment_count를 포함하여 학습 → R^2 = 0.95
2. "너무 좋은데?" 의심 → 시간 순서 검토
3. **발견: 좋아요/댓글은 조회수의 '결과'임** (업로드 후에 발생)
4. like_count, comment_count 제외 후 재학습 → R^2 = 0.74

Data Leakage란?

학습 데이터에 예측 시점에 알 수 없는 정보가 포함된 경우를 말합니다. 모델 성능은 높게 나오지만 실제 예측에서는 사용할 수 없는 **'가짜 성능'**이 됩니다.

```
영상 업로드 → 시청 (view_count) → 좋아요 (like_count) → 댓글 (comment_count)
```

→ 교훈: 높은 성능이 나와도 비판적으로 검토해야 함. 실제 사용 시나리오를 항상 고려해야 함

---

5. 모델링 및 성능 평가

5.1 모델 발전 과정

단계별로 모델을 개선하며 각 변화가 성능에 미치는 영향을 측정했습니다.

단계	변경 사항	R^2	MAE	개선율
베이스라인	숫자 컬러만, 전처리 없음	0.28	-	-

전처리 추가	로그 변환 + Feature Engineering	0.42	1.34	+50%
알고리즘 변경	Linear → Boosted Tree	0.74	0.92	+164%
AutoML	**Vertex AI AutoML 자동 최적화**	**0.80**	**0.79**	**+186%**

5.2 Feature 중요도 분석

ML.FEATURE_IMPORTANCE를 통해 각 Feature가 예측에 미치는 영향도를 분석했습니다.

순위	Feature	중요도	해석
1	duration_seconds	735	영상 길이가 조회수에 큰 영향
2	log_channel_avg_views	680	채널 평균이 개별 영상 예측의 핵심
3	channel_video_count	500	채널 활동량도 중요한 지표
4	log_subscribers	495	구독자 수의 영향력
5	tag_count	335	태그 개수도 검색 노출에 영향

핵심 인사이트:

- **채널 파워 (45%):** log_channel_avg_views + log_subscribers + channel_video_count가 전체 중요도의 약 45%
- **콘텐츠 특성 (25%):** duration_seconds, tag_count
- **제목 키워드 (15%):** has_mukbang, has_recipe 등은 상대적으로 낮은 영향

→ **결론:** '누가 올리느냐'가 '무슨 내용이냐'보다 조회수에 더 큰 영향을 미침

---

6. 모델 배포 및 서비스화

6.1 Vertex AI Endpoint 배포

학습된 모델을 Vertex AI Endpoint에 배포하여 **REST API로 실시간 예측이 가능한 서비스**를 구축했습니다.

```
[ 클라이언트 요청 ] → [ Vertex AI Endpoint ] → [ 예측 결과 반환 ]
```

배포 구성:

- 엔드포인트: Vertex AI Online Prediction
- 리전: us-central1
- 입력: 17개 Feature (JSON 형식)
- 출력: log_view_count (로그 스케일 예측값)

6.2 시나리오별 예측 테스트

실제 서비스 활용 시나리오를 가정하여 다양한 조건으로 예측 테스트를 수행했습니다.

시나리오	예측 조회수	비고
대형 채널 (100만 구독) + 먹방	121,122회	기준 시나리오

대형 채널 (100만 구독) + 레시피	121,122회	키워드 영향 없음
대형 채널 (100만 구독) + 주말	121,122회	시간 영향 없음
소형 채널 (1만 구독) + 먹방	2,684회	**45배 차이**
소형 채널 (1만 구독) + 레시피	2,461회	키워드 9% 영향

테스트 결과 인사이트:

- **채널 규모 효과:** 대형 vs 소형 채널 간 약 45배 조회수 차이
- **대형 채널 특성:** 키워드나 업로드 시간 변경해도 예측값 동일 (채널 파워가 압도적)
- **소형 채널 특성:** 키워드 선택이 약 9% 조회수 차이 발생 (먹방 > 레시피)

---

7. 결론 및 향후 계획

7.1 프로젝트 성과 요약

항목	결과
수집 데이터	68,497개 영상, 15개 컬럼
Feature Engineering	17개 Feature 생성
모델 성능 향상	**R^2 0.28 → 0.80 (186% 향상)**
문제 해결	Data Leakage 발견 및 해결
배포	Vertex AI Endpoint API 서비스화

7.2 비즈니스 인사이트

1. **채널 성장이 최우선:** 조회수의 45%는 채널 파워가 결정. 신규 크리에이터는 키워드 최적화보다 채널 성장에 집중해야 함
2. **대형 채널은 자유롭게:** 구독자 100만 이상 채널은 키워드나 업로드 시간에 크게 구애받지 않음
3. **소형 채널의 전략:** 구독자 1만 이하 채널은 키워드 선택이 약 9% 조회수 차이 발생. '먹방' 키워드가 '레시피'보다 유리

7.3 기술적 교훈

- **EDA의 중요성:** 데이터 분포 확인 없이 모델링하면 성능 저하 (로그 변환 필요성 발견)
- **Data Leakage 주의:** 높은 성능이 나와도 비판적으로 검토해야 함
- **Feature Engineering 효과:** 알고리즘 변경만큼 성능 향상에 기여

7.4 향후 확장 계획

- **웹 UI 개발:** 일반 사용자도 쉽게 예측할 수 있는 인터페이스 구축
- **썸네일 분석:** Vision AI를 활용한 이미지 Feature 추가
- **실시간 트렌드 반영:** 시계열 Feature 및 모델 재학습 파이프라인 구성

---

8. 활용 기술 역량 정리

분야	기술	활용 내용
데이터 수집	Python, YouTube API	68,497개 영상 메타데이터 수집
데이터 저장	Google BigQuery	테이블 설계, 스키마 관리

데이터 분석	SQL, EDA	분포 분석, 패턴 발견, 인사이트 도출
Feature Engineering	SQL 변환, 집계	17개 Feature 설계 및 생성
머신러닝	BigQuery ML, Vertex AI	회귀 모델 학습, AutoML 활용
모델 배포	Vertex AI Endpoint	REST API 서비스화
클라우드	GCP	BigQuery, Vertex AI 통합 활용